Servicio Nacional de Aprendizaje

SENA

Proceso de Gestión de Formación Profesional Integral

GUÍA DE APRENDIZAJE Nº 1: Datos, Información, Toma de Decisiones, Fuentes y Formatos



Autor: Ing. Nathalia Martinez Vargas
nmmartinez@sena.edu.co

Procesamiento de Datos para Modelos de Inteligencia Artificial

Trimestre I

Centro de Materiales y Ensayos

26 de octubre de 2026

Bogotá D.C.

Tabla de contenido

1 Presentación **2**

2 Actividades **2**

2.1 Actividades de reflexión inicial 2

2.1.1 Actividades a Desarrollar 4

2.2 Actividades de contextualización e identificación de conocimientos 5

2.3 Actividades de Apropiación del Conocimiento 5

2.4 Actividades de Transferencia de Conocimiento 6

2.4.1 Desarrollo del Diccionario de Datos 6

3 Condiciones de entrega **6**

Referencias **8**

Competencia Evaluada	Integración de datos desde múltiples fuentes de datos
Resultado de Aprendizaje (RAP)	RAP 2: Alistar datos para una solución IA según técnicas de tratamiento de datos y la necesidad del negocio
Duración de la Guia	20 horas

1 Presentación

¡Bienvenido a la Guía de Aprendizaje Nº 1!.

Partiendo de la experiencia empírica cotidiana en la toma de decisiones, esta unidad enlaza dichos conocimientos previos con el ciclo conceptual formal que transforma los datos crudos en información útil para el direccionamiento estratégico. El dominio de este proceso aportará le aportará fortalezas significativas, orientadas a potenciar su pensamiento analítico y su destreza en la resolución de problemas complejos. Para guiar y organizar este aprendizaje hacia el desarrollo integral, se explorarán fuentes de datos abiertos reales de Kaggle, OpenML, Datos Abiertos Bogotá y Datos Abiertos Colombia (Datos Abiertos Bogotá, s. f.; Datos Abiertos Colombia, s. f.; Kaggle, s. f.; OpenML, s. f.), se clasificarán diversos tipos de datos y se abordarán los formatos planos y estructurados CSV y XLSX. En virtud de alcanzar estos objetivos, se exhorta al aprendiz a la acción mediante un trabajo autónomo, sistemático y organizado de los recursos. Finalmente, dado que el análisis de datos se consolida a través de múltiples perspectivas, se promueve activamente el aprendizaje colaborativo como pilar fundamental para propiciar el crecimiento integral del grupo.

¡Manos a la obra!

2 Actividades

2.1 Actividades de reflexión inicial

Caso de estudio:

Durante el pico de la pandemia de COVID-19 en octubre de 2020, el gobierno del Reino Unido, a través de la agencia Public Health England (PHE), dependía de la recopilación masiva de datos para tomar decisiones estratégicas diarias. Estas decisiones incluían la imposición de restricciones de movilidad, la asignación de recursos hospitalarios y, lo más crítico, el rastreo inmediato de contactos de las personas infectadas para contener la propagación del virus. PHE detectó un fallo en la transferencia automatizada de archivos de los laboratorios a sus sistemas.

Entre el 25 de septiembre y el 2 de octubre, 15.841 resultados positivos no se incluyeron en las cifras diarias publicadas ni se transfirieron oportunamente al sistema de rastreo de contactos (House of Commons, 2020, p. 625).

La nota periodística de Leo Kelion para BBC News explica que los laboratorios comerciales que procesaban las pruebas enviaban los resultados diarios al sistema central de PHE en formato de texto plano (CSV). Posteriormente, un proceso automatizado tomaba estos archivos y los importaba a plantillas de Microsoft Excel en el formato antiguo XLS para que los analistas pudieran consolidar la información y alimentar los tableros de control (dashboards) (Kelion, 2020).

El error fatal ocurrió en la elección del formato estructural, el sistema automatizado fue configurado para consolidar los datos utilizando el formato heredado de Excel (.xls), en lugar del formato moderno (.xlsx) o mantener el procesamiento nativo en texto plano (.csv).

Al agrupar los resultados de las pruebas en columnas dentro de este archivo heredado, el volumen de datos superó rápidamente el límite de las 65.536 filas. El sistema simplemente cortó los datos excedentes sin generar ninguna alerta de error; al alcanzar el límite, los resultados restantes quedaban fuera del proceso de carga al sistema central.

Como resultado directo de esta mala gestión en el formato de los datos, se presentó que exactamente 15.841 resultados positivos de COVID-19 no se registraron en los sistemas centrales. Durante varios días, los tableros de control mostraron una falsa disminución en los casos de contagio. Los tomadores de decisiones a nivel gubernamental asumieron que las medidas de contención estaban funcionando, cuando en realidad la curva estaba en ascenso.

Dado que estos casi 16.000 casos positivos "desaparecieron" del sistema, no se enviaron a los centros de rastreo. Se estima que alrededor de 50.000 contactos estrechos no fueron advertidos a tiempo de su exposición al virus, lo que aceleró la propagación en las comunidades (Halliday et al., 2020).

El problema afectó la publicación de las cifras y el paso de esos resultados al rastreo, pero no significa que las personas con resultados positivos quedaran sin notificación: el secretario de Salud informó que habían recibido sus resultados y la indicación de aislarse en el plazo habitual (House of Commons, 2020, p. 625). En cambio, se estimó que más de 50.000 contactos cercanos podrían no haber sido localizados oportunamente. Esa cifra es una estimación basada en promedios de contactos por caso, no un conteo confirmado de personas omitidas (Halliday et al., 2020).

El incidente dejó incompletos temporalmente los datos de los tableros de control. Sin embargo, el secretario de Salud sostuvo que la información corregida no modificaba sustancialmente la evaluación de la epidemia ni la base de las decisiones locales adoptadas (House of Commons, 2020, p. 625).

2.1.1 Actividades a Desarrollar

1. Documentar de manera concisa las diferencias estructurales entre un archivo de texto plano (CSV), un formato de hoja de cálculo heredado (XLS) y uno moderno (XLSX), haciendo énfasis en sus límites de almacenamiento (filas y columnas) e identificando en qué punto exacto falló la integridad de los datos en el caso expuesto.

2. Elaborar un esquema conceptual que ilustre cómo debió ser el tránsito seguro de la información desde los laboratorios (origen) hasta el tablero de control gubernamental (destino). Se debe justificar qué formatos (CSV o XLSX) debieron emplearse en cada etapa para garantizar la preservación de los casi 16.000 registros perdidos.

3. Redactar una conclusión analítica sobre la relación directa entre el conocimiento técnico del analista de datos y la responsabilidad ética en la toma de decisiones a nivel gerencial o gubernamental.

2.2 Actividades de contextualización e identificación de conocimientos

Cada equipo de trabajo deberá escoger una témática que quiera estudiar y elaborar una bitácora de exploración y clasificación de datos, debe contener la siguiente estructura:

- Enunciado del eje temático concertado por el equipo y una breve justificación de su elección.
- Un párrafo argumentativo donde el equipo clasifique y justifique si los conjuntos de datos que van a utilizar corresponden a fuentes de extracción primarias o secundarias.
- Un listado de al tres (3) conjuntos de datos descubiertos durante la exploración en los portales (Kaggle, OpenML, Datos Abiertos Bogotá y Datos Abiertos Colombia) (Datos Abiertos Bogotá, s. f.; Datos Abiertos Colombia, s. f.; Kaggle, s. f.; OpenML, s. f.), especificando para cada uno: nombre del dataset, portal de alojamiento y enlace (URL) de acceso.
- Una tabla estructurada que extraiga un mínimo de treinta (30) variables o columnas observadas durante la exploración de los datasets seleccionados, en la cual se clasifique rigurosamente cada variable en su respectiva categoría estadística (**Cualitativa:** nominal u ordinal; **Cuantitativa:** discreta o continua)

2.3 Actividades de Apropiación del Conocimiento

Con base en la temática concertada previamente, cada equipo seleccionará y descargará dos (2) datasets reales (obligatoriamente uno en formato CSV y otro en formato XLSX) alojados en los portales explorados. A continuación, ejecutarán una auditoría técnica rigurosa sobre ambos archivos para descubrir y documentar por lo menos seis (6) inconsisitencias en los datos. Para la explicación de los problemas encontrados use la siguiente estructura:

- ¿Qué o cuál es problema?
- ¿Cómo se ha detectado?
- ¿Por qué cree que se trata de un problema?

- ¿Un ejemplo completo extraído del propio dataset?

2.4 Actividades de Transferencia de Conocimiento

El equipo de trabajo seleccionará el dataset que consideren más robusto de los dos auditados en la fase anterior. Utilizando la información contenida en dicho archivo, procederán a documentar técnicamente la estructura completa del archivo mediante un instrumento de metadatos (Diccionario de datos).

2.4.1 Desarrollo del Diccionario de Datos

Para cada variable (columna) del dataset principal seleccionado, el equipo construirá una matriz registrando rigurosamente:

1. **Nombre original de la variable:** (Tal cual aparece en el archivo fuente)
2. **Nombre estandarizado sugerido:** Propuesta de nombre técnico sin espacios, sin tildes y en minúsculas por ejemplo (promedio_nota).
3. **Clasificación estadística:** Cualitativa (nominal/ordinal) o Cuantitativa (discreta/continua).
4. **Tipo de dato técnico:** Cadena de texto, numérico entero, numérico decimal, fecha, booleano, arreglo o colección, null.
5. **Descripción semántica:** Explicación precisa de qué representa esa columna o atributo en el contexto de su temática.
6. **Unidad de medida o formato:** (ej. COP, metros, porcentaje, formato DD/MM/AAAA).

3 Condiciones de entrega

- Fecha de entrega: Martes 3 de noviembre de 2026 a las 2:00 p.m.

- Generar un único documento con la solución de las actividades
- El documento debe estar en Normas APA
- En el documento deben estar los nombres completos de los integrantes del equipo
- Subir los datasets y el documento con la solución al repositorio en GitHub de cada uno de los integrantes.
- Al correo nmmartinez@sena.edu.co se debe enviar el nombre de los integrantes del equipo y el enlace de los repositorio de GitHub, (Verificar que todos funcionen de manera correcta)
- Debe citar a los autores de los datasets (Solo si estos presentan autores), también si realiza consultas en internet debe referenciar los enlaces revisados.
- Si utilizó alguna Inteligencia Artificial (Chat GPT, Claude, Copilot, Gemini, DeepSeek, Perplexity, etc) para el desarrollo de la guia, comente en cuales ejercicios fue usado y en cuanto porcentaje (%)

Referencias

Datos Abiertos Bogotá. (s. f.). *Plataforma Distrital de Datos Abiertos*. https://datosabiertos.bogota.gov.co/

Datos Abiertos Colombia. (s. f.). *Portal de Datos Abiertos de Colombia*. https://www.datos.gov.co/

Halliday, J., Campbell, D., Walker, P., & Sample, I. (2020, 5 de octubre). *England Covid cases error means 50,000 contacts may not have been traced*. The Guardian. https://www.theguardian.com/world/2020/oct/05/england-covid-cases-error-unknown-how-many-contacts-not-traced-says-minister

House of Commons. (2020, 5 de octubre). *Covid-19 update* [Debate parlamentario]. Hansard. https://hansard.parliament.uk/pdf/commons/2020-10-05

Kaggle. (s. f.). *Datasets*. https://www.kaggle.com/data

Kelion, L. (2020, 5 de octubre). *Excel: Why using Microsoft's tool caused Covid-19 results to be lost*. BBC News. https://www.bbc.co.uk/news/technology-54423988

OpenML. (s. f.). *Datasets*. https://www.openml.org/search?type=data